

Implementación y Análisis de Inferencia de E2D2: un Transformer Encoder–Decoder de Difusión Discreta para Traducción Automática

Procesamiento de Datos Secuenciales con Deep Learning
Universidad Autónoma Occidente
Especialización 202601

Nicolás Vásquez Renjifo

nicolas.vasquez@uao.edu.co

Ingeniero Mecatrónico

Jorge Luis Fong Gutierrez

jorge.fong@uao.edu.co

Ingeniero Mecatrónico

Jhonatan David Rengifo
Bermeo

jhonatan.rengifo@uao.edu.co

Ingeniero Mecatrónico

Mateo González Ruiz

mateo.gonzalez@uao.edu.co

Ingeniero Mecatrónico

Resumen—Este trabajo presenta la implementación y evaluación experimental de E2D2, una arquitectura Transformer encoder–decoder basada en modelos de difusión discreta para lenguaje natural. El proyecto responde a la consigna de implementar inferencia sobre una arquitectura Transformer encoder–decoder aplicada a datos secuenciales complejos, sin entrenar desde cero, utilizando un artículo científico con código y pesos preentrenados disponibles. Se utiliza el checkpoint `kuleshov-group/e2d2-wmt`, entrenado sobre WMT14 de-en, y se evalúa su comportamiento en traducción alemán–inglés. El estudio incluye inspección interna de la arquitectura, inferencia en Google Colab, un estudio de ablación sobre `block_size`, pasos de difusión y caché, comparación extendida con el baseline autoregresivo `Helsinki-NLP/opus-mt-de-en`, y análisis cualitativo de errores. Los resultados muestran que la configuración oficial de E2D2, `block_size=4` y `num_steps=4`, es la más equilibrada entre las variantes E2D2 evaluadas. En la evaluación extendida de 150 ejemplos, E2D2 obtiene BLEU 16.53 y chrF 49.66, mientras que OPUS-MT obtiene BLEU 25.02 y chrF 54.09. Estos resultados permiten discutir críticamente las diferencias entre decodificación autoregresiva y generación por denoising discreto.

Index Terms—Transformer, encoder–decoder, difusión discreta, E2D2, traducción automática, inferencia, WMT14.

I. INTRODUCCIÓN

Los modelos Transformer han dominado gran parte del procesamiento de lenguaje natural debido a su capacidad para modelar dependencias de largo alcance en secuencias. Tradicionalmente, las tareas de generación de texto, como traducción o resumen, se han abordado con modelos autoregresivos que generan un token a la vez. Aunque este paradigma es efectivo, su naturaleza secuencial limita la paralelización durante la inferencia.

El artículo *Encoder-Decoder Diffusion Language Models for Efficient Training and Inference* propone E2D2, una arquitectura Transformer encoder–decoder que adapta modelos de difusión discreta al modelado de lenguaje [1]. La idea central es separar dos tipos de computación: la representación de tokens limpios mediante un encoder grande, y el denoising

iterativo de tokens corruptos mediante un decoder más liviano. Esta separación busca mejorar la eficiencia de inferencia respecto a modelos de difusión decoder-only.

Este proyecto implementa inferencia con E2D2 sobre traducción alemán–inglés. La tarea se considera adecuada para la consigna porque el lenguaje natural es una secuencia compleja y no corresponde a series de tiempo tabulares o sensores. Además, el paper seleccionado cuenta con repositorio oficial, integración en Hugging Face y pesos preentrenados disponibles [2], [3].

II. OBJETIVOS

El objetivo general es implementar y analizar una arquitectura Transformer encoder–decoder aplicada a datos secuenciales complejos, usando inferencia con pesos preentrenados.

Los objetivos específicos son:

- Revisar la arquitectura E2D2 propuesta en el artículo base.
- Cargar pesos preentrenados oficiales y ejecutar inferencia en Google Colab.
- Inspeccionar la configuración interna del modelo cargado.
- Evaluar el impacto de `block_size`, `num_steps` y uso de caché.
- Comparar E2D2 contra un baseline Transformer encoder–decoder autoregresivo.
- Analizar errores cualitativos de traducción y discutir limitaciones.

III. CUMPLIMIENTO DE LA CONSIGNA

La Tabla I resume cómo el proyecto satisface explícitamente los requisitos de la consigna.

IV. ARQUITECTURA E2D2

E2D2 es una arquitectura encoder–decoder diseñada para modelos de difusión discreta en lenguaje. A diferencia de un Transformer encoder–decoder clásico, donde el decoder suele

Tabla I
VERIFICACIÓN DE CUMPLIMIENTO DE LA CONSIGNA

Requisito	Cumplimiento en el proyecto
Arquitectura Transformer encoder-decoder	Se implementa inferencia con E2D2, una arquitectura con encoder Transformer y decoder Transformer de difusión.
Datos secuenciales complejos	Se trabaja con lenguaje natural, específicamente traducción automática alemán-inglés.
No usar series de tiempo tradicionales	No se usan datos tabulares, sensores ni registros estructurados.
Artículo científico base	El proyecto se basa en el paper <i>Encoder-Decoder Diffusion Language Models for Efficient Training and Inference</i> .
Código disponible	Se usa el repositorio oficial publicado por Kuleshov Group.
Pesos preentrenados	Se usa el checkpoint público <code>kuleshov-group/e2d2-wmt</code> .
No entrenar desde cero	Solo se ejecuta inferencia y evaluación con pesos preentrenados.
Explicación profunda	Se documentan arquitectura, block diffusion, máscaras conceptuales, métricas, ablación, baseline y errores.

generar tokens autoregresivamente, E2D2 utiliza un decoder de difusión que refina tokens ruidosos o enmascarados.

IV-A. Componentes

La arquitectura divide el procesamiento en dos módulos principales:

- **Encoder:** procesa tokens limpios, como el prompt, la fuente alemana o bloques ya generados. En el checkpoint WMT usado, el encoder tiene 28 capas.
- **Decoder:** realiza denoising sobre el bloque activo. En el checkpoint WMT usado, el decoder tiene 4 capas.

Esta asimetría permite que el encoder, más costoso, se invoque con menor frecuencia, mientras que el decoder, más pequeño, puede ejecutarse múltiples veces durante el refinamiento de cada bloque.




Figura 1. Flujo conceptual de inferencia en E2D2. El encoder representa tokens limpios y el decoder refina tokens ruidosos por bloques.

IV-B. Block Diffusion

En block diffusion, la secuencia se divide en bloques de tamaño S . Para cada bloque, el modelo parte de una representación ruidosa y aplica pasos de denoising. La inferencia puede representarse conceptualmente como:

1. Codificar la secuencia fuente con el encoder.

2. Inicializar un bloque objetivo con tokens ruidoso.
3. Ejecutar T pasos de denoising con el decoder.
4. Agregar el bloque generado al contexto.
5. Repetir hasta completar la secuencia.

El checkpoint E2D2-WMT utiliza `block_size=4` y `num_steps=4` como configuración oficial.

V. METODOLOGÍA

V-A. Entorno

Los experimentos se ejecutaron en Google Colab con GPU Tesla T4 y 15.64 GB de VRAM. Aunque el notebook incluye detección experimental de TPU/XLA, la corrida registrada se realizó con CUDA. Las dependencias principales fueron `transformers==4.52.4`, `accelerate==1.11.0`, `datasets==4.2.0`, `evaluate`, `sacrebleu` y `sentencepiece`.

V-B. Modelo Principal

El modelo principal fue `kuleshov-group/e2d2-wmt`, publicado en Hugging Face. La Tabla II resume los atributos inspeccionados directamente desde el checkpoint.

Para reproducibilidad, se fijó la revisión exacta del checkpoint E2D2-WMT en Hugging Face: `7c65309acc0d6d89049c9aca4ea02f9d10d1da5a`. El baseline OPUS-MT también se fijó a la revisión `1a922f3b32a8e809e17a47d4b32142d8105924e5`. Esto evita que una actualización remota altere silenciosamente los resultados.

Tabla II
CONFIGURACIÓN INSPECCIONADA DEL CHECKPOINT E2D2-WMT

Atributo	Valor
Tipo de modelo	E2D2
Tipo de difusión	absorbing
Capas del encoder	28
Capas del decoder	4
Hidden size	512
Intermediate size	1536
Block size	4
Longitud máxima	256
Tokenizer	Qwen/Qwen3-0.6B-Base
Parámetros totales	331.8M

V-C. Dataset

Se utilizó una muestra inicial de 30 ejemplos del conjunto de prueba WMT14 de-en para el estudio de ablación y análisis cualitativo. Adicionalmente, el notebook final incluye una sección de evaluación extendida configurada para 150 ejemplos, enfocada en comparar la configuración oficial de E2D2 contra el baseline OPUS-MT. Cada ejemplo contiene una fuente en alemán y una referencia humana en inglés. El tamaño de muestra extendido busca mejorar la robustez empírica sin convertir el proyecto en una reproducción completa de todas las evaluaciones del paper.

V-D. Baseline

Para contrastar E2D2 con una arquitectura encoder-decoder autoregresiva tradicional, se utilizó Helsinki-NLP/opus-mt-de-en, un modelo OPUS-MT alemán-inglés [4]. Este baseline tiene aproximadamente 74.4M parámetros y genera traducciones mediante decodificación autoregresiva.

V-E. Métricas

Se reportaron las siguientes métricas:

- **BLEU**: métrica estándar de traducción automática basada en coincidencias de n-gramas [5].
- **chrF**: métrica basada en F-score de caracteres, útil para variaciones morfológicas y lexicales [6].
- **Tiempo promedio**: segundos por ejemplo.
- **Tokens por segundo**: throughput de generación.
- **Repetición de bigramas**: tasa simple de bigramas repetidos en la salida.

VI. IMPLEMENTACIÓN

La inferencia se implementó en un notebook de Colab. La entrada alemana se construyó como:

```
BOS + texto_aleman + EOS
```

Luego, el modelo E2D2 generó la continuación en inglés. Para cada traducción se midió tiempo, número de tokens generados, tokens por segundo y texto resultante. También se exportaron archivos CSV con resultados por configuración y análisis cualitativo.

El notebook final documentado contiene comentarios en las líneas importantes del código: carga de dependencias, selección de dispositivo, carga del checkpoint, construcción del prompt, generación E2D2, métricas, ablación, baseline OPUS-MT y exportación de resultados.

VII. RESULTADOS

VII-A. Ablation Study de E2D2

La Tabla III muestra los resultados de las configuraciones E2D2 evaluadas. La configuración oficial del checkpoint fue la más equilibrada.

La configuración `b2/s2` generó salidas demasiado cortas, con apenas dos tokens en promedio. La configuración `b8/s8` aumentó los tokens por segundo, pero deterioró BLEU y elevó la repetición. La ruta `use_cache=False` falló en todos los

ejemplos con un error de dimensiones, por lo que se reporta como limitación técnica de esta implementación y no como resultado competitivo.

VII-B. Comparación Extendida con OPUS-MT

La Tabla IV compara E2D2 con el baseline autoregresivo OPUS-MT sobre 150 ejemplos del conjunto de prueba WMT14 de-en. Esta comparación extendida se usa como resultado principal de evaluación, mientras que la Tabla III se mantiene como estudio de sensibilidad de parámetros.

En esta muestra extendida, OPUS-MT supera a E2D2 en calidad automática y velocidad. Esto no invalida E2D2 como objeto de estudio, ya que el propósito principal del proyecto es comprender e implementar una arquitectura encoder-decoder de difusión discreta con pesos preentrenados. La comparación permite discutir diferencias arquitectónicas: OPUS-MT es un traductor autoregresivo especializado, mientras E2D2 genera mediante refinamiento discreto por bloques.

VIII. ANÁLISIS CUALITATIVO

El análisis cualitativo muestra que E2D2 puede generar traducciones razonables, pero también presenta errores de repetición y continuaciones no justificadas. Por ejemplo, para la frase alemana:

Pro Fahrtrichtung gibt es drei Lichtenanlagen.

La referencia es:

There are three sets of lights per direction of travel.

E2D2 produjo:

There are three light systems per direction. The car is 100 m long and 100 m long...

OPUS-MT produjo:

There are three lighting systems per direction of travel.

Este caso evidencia una limitación práctica del sampling E2D2 en esta configuración: el modelo puede traducir correctamente el inicio, pero luego extenderse con contenido repetitivo o ajeno a la fuente. Por ello se incluyó una métrica simple de repetición de bigramas.

IX. DISCUSIÓN

Los resultados confirman que la configuración oficial de E2D2-WMT es la más razonable dentro de las variantes evaluadas. La reducción de `block_size` a 2 produce generación insuficiente, mientras que aumentarlo a 8 incrementa la longitud y la repetición. Esto es coherente con el trade-off reportado en el paper: el tamaño de bloque afecta calidad, velocidad y frecuencia con la que se actualiza el contexto.

La comparación con OPUS-MT muestra que un modelo autoregresivo especializado puede ser más fuerte en una evaluación acotada de traducción. Sin embargo, el interés de E2D2 no está en reemplazar directamente a todos los traductores autoregresivos, sino en explorar una arquitectura alternativa donde la generación se formula como denoising discreto. Esta perspectiva es relevante para estudiar nuevas formas de paralelización y eficiencia en modelos de lenguaje.

Tabla III
ABLATION STUDY DE E2D2 SOBRE 30 EJEMPLOS WMT14 DE-EN

Configuración	BLEU	chrF	Tiempo (s)	Tokens/s	Tokens gen.	Rep. bigrama
E2D2 b2/s2 cache	0.00	0.31	0.140	15.75	2.00	0.033
E2D2 b4/s4 cache	17.85	50.00	1.066	37.24	36.53	0.092
E2D2 b8/s8 cache	10.13	45.65	0.950	71.03	65.87	0.240
E2D2 b4/s4 no-cache	—	—	—	—	—	—

Tabla IV
COMPARACIÓN EXTENDIDA ENTRE E2D2 Y BASELINE AUTOREGRESIVO SOBRE 150 EJEMPLOS

Modelo	BLEU	chrF	Tiempo (s)	Tokens/s	Rep. bigrama
E2D2 b4/s4 cache	16.53	49.66	0.706	50.32	0.077
OPUS-MT autoregresivo	25.02	54.09	0.189	144.68	0.005

X. LIMITACIONES

Las principales limitaciones del proyecto son:

- Las ablaciones se ejecutan sobre una muestra reducida para controlar el tiempo de cómputo en Colab; la comparación principal E2D2 vs. OPUS-MT se ejecutó sobre 150 ejemplos.
- No se reproduce el entrenamiento desde cero porque la consigna prioriza inferencia con pesos preentrenados y análisis arquitectónico; entrenar E2D2-WMT excede los recursos razonables de Colab.
- El baseline OPUS-MT es más pequeño pero altamente especializado para traducción.
- Las métricas automáticas en muestras acotadas pueden variar y deben complementarse con análisis cualitativo.

XI. CONCLUSIONES

El proyecto implementó exitosamente inferencia con E2D2, una arquitectura Transformer encoder-decoder de difusión discreta aplicada a traducción automática. Se verificó internamente la estructura del checkpoint, confirmando un encoder de 28 capas y un decoder de 4 capas, con 331.8M parámetros. La configuración oficial `block_size=4`, `num_steps=4` y caché activado fue la variante E2D2 más equilibrada. La comparación con OPUS-MT mostró que el baseline autoregresivo fue superior en esta muestra, pero también permitió contextualizar las fortalezas y debilidades de la generación por difusión discreta.

En conjunto, la entrega cumple la consigna: se basa en un paper científico, usa código y pesos preentrenados disponibles, no entrena desde cero, implementa inferencia, trabaja con datos secuenciales complejos y explica en profundidad el funcionamiento de una arquitectura Transformer encoder-decoder.

REFERENCIAS

- [1] M. Arriola, Y. Schiff, H. Phung, A. Gokaslan, and V. Kuleshov, “Encoder-decoder diffusion language models for efficient training and inference,” in *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025. [Online]. Available: <https://arxiv.org/abs/2510.22852>
- [2] Kuleshov Group, “E2d2: Encoder-decoder diffusion language models for efficient training and inference,” <https://github.com/kuleshov-group/e2d2>, 2025, repositorio oficial.
- [3] —, “kuleshov-group/e2d2-wmt,” <https://huggingface.co/kuleshov-group/e2d2-wmt>, 2025, checkpoint preentrenado para WMT14 de-en.
- [4] J. Tiedemann and S. Thottingal, “Opus-mt – building open translation services for the world,” in *Proceedings of the 22nd Annual Conference of the European Association for Machine Translation*, 2020, pp. 479–480.
- [5] M. Post, “A call for clarity in reporting bleu scores,” in *Proceedings of the Third Conference on Machine Translation: Research Papers*, 2018, pp. 186–191.
- [6] M. Popović, “chrF: character n-gram f-score for automatic mt evaluation,” in *Proceedings of the Tenth Workshop on Statistical Machine Translation*, 2015, pp. 392–395.